

AirChoice 레이블 설계 근거

작성일: 2026-04-30

목적: 팀원이 레이블 설계 탐색 과정을 이해하고, 확정된 레이블을 그대로 사용하기 위한 문서

결론 먼저

```
label = (saving_pct > cv_pct).astype(int)
# 0 = BUY (지금 사는 게 유리)
# 1 = WAIT (기다리는 게 유리)
```

이 레이블은 **변경하지 않는다**. 이유는 아래에 설명한다.

구성 요소 정의

saving_pct (타겟 변수)

```
# trajectory 내에서 현재 시점 이후의 실제 최저가
residual_min = df.sort_values(['traj_id', 'dpd'])
                  .groupby('traj_id')['price_krw']
                  .transform(lambda x: x.expanding().min())

saving_pct = (price_krw - residual_min) / price_krw * 100
saving_pct = saving_pct.clip(lower=0)
```

의미: 지금 가격이 이후 실제 최저가 대비 얼마나 비싼가 (%)

예시: saving_pct=15 → 지금 사면 이후 최저가 대비 15% 더 싸게 사는 것

주의: Hindsight 레이블 — 실제 서비스에서는 1단계 모델이 이 값을 예측

cv_pct (기다림 비용 기준선)

```
# 편명 단위로 DPD 구간별 가격 변동계수
cv_pct = STD(price_krw) / AVG(price_krw) * 100
```

의미: 이 항공편의 가격이 얼마나 변동성이 큰가 (%)

역할: 기다려서 얻을 수 있는 절약이 변동 위험을 감수할 만한지 판단하는 기준선

예시: cv_pct=5 이고 saving_pct=15 → 기다릴 가치 있음 → WAIT

탐색한 대안들과 기각 이유

대안 1: 클러스터링으로 레이블 대체

시도 내용:

- trajectory 단위 K-Means (K=2~6)
- DPD 단위 클러스터링
- Hindsight 피처 클러스터링

기각 이유:

- 클러스터 결과가 BUY/WAIT 의미와 일치하지 않음
- 어떤 클러스터가 BUY인지 사후 해석이 필요 → 레이블 의미 불명확
- 데이터가 증가하면 클러스터 경계가 달라짐 → 재현성 없음
- **결론:** 클러스터링은 피처로만 활용 가능, 레이블 대체 불가

대안 2: 단순 가격 하락 여부

```
# 검토했으나 기각
label = (future_min_price < current_price).astype(int)
```

기각 이유:

- 1원만 내려가도 WAIT가 됨 → 지나치게 민감
- 실제로 기다릴 가치가 있는지와 무관
- 변동성이 높은 항공편과 낮은 항공편을 동일하게 취급

대안 3: 절약 금액 절대값 기준

```
# 검토했으나 기각
label = (saving_krw > 30000).astype(int) # 예시
```

기각 이유:

- 10만원 티켓에서 3만원 절약 vs 100만원 티켓에서 3만원 절약은 다른 의미
- 노선별 가격대가 달라서 동일 기준 적용 불가
- 임계값(3만원) 설정 근거 없음

대안 4: saving_pct 고정 임계값

```
# 검토했으나 기각
label = (saving_pct > 10).astype(int) # 예시
```

기각 이유:

- 임계값 10%의 근거가 없음
- 변동성이 낮은 항공편(cv_pct=2%)에서 10%는 매우 큰 기회

- 변동성이 높은 항공편(cv_pct=30%)에서 10%는 노이즈 수준
- 노선별/편명별 특성을 반영하지 못함

현재 레이블의 장점

1. 변동성을 기준으로 내재화

cv_pct가 기준선이 되므로, 변동성이 높은 항공편은 더 엄격하게, 낮은 항공편은 더 관대하게 WAIT를 판단한다.

```
cv_pct=3%, saving_pct=5% → 5 > 3 → WAIT (변동성 대비 절약 크다)
cv_pct=20%, saving_pct=5% → 5 < 20 → BUY (변동성 대비 절약 작다)
```

2. 항공편별 상대적 기준

절대 금액이 아닌 해당 항공편의 특성에 맞는 기준으로 레이블이 결정된다.

3. 레이블 비율

구분	BUY(0)	WAIT(1)	비율
편도	~20,000	~46,000	1:2.2
왕복	~37,000	~157,000	1:4.2

WAIT가 더 많은 건 정상이다. 특정 DPD에서 지금 사는 게 최선인 경우보다 더 기다려서 싸게 살 수 있는 경우가 더 많기 때문이다.

주의사항

saving_margin을 2단계 피처로 쓰면 안 되는 이유

```
# 절대 사용 금지
saving_margin = pred_saving - cv_pct
label = (saving_margin > 0).astype(int)
```

이유: 2단계에서 pred_saving으로 레이블을 생성했는데, 같은 pred_saving을 피처로 넣으면 Tautology(동어반복)가 된다.

모델이 saving_margin > 0이면 WAIT, 아니면 BUY라는 단순 규칙만 학습하게 된다.

허용되는 2단계 피처:

```
S2_FEAT = [
    'pred_saving',          # 1단계 출력 (허용)
    'dpd', 'dpd_ratio',
    'price_pct_from_cum_min',
```

```
'price_pct_from_cum_mean',
'price_chg_1', 'price_chg_3',
'cv_pct', # 기준선 (허용, saving_margin 계산 전 원값)
'route_enc', 'airline_enc', 'flight_enc',
]
```

traj_std, traj_mean 등 trajectory 전체 통계 사용 금지

```
# 절대 사용 금지
traj_std = df.groupby('traj_id')['price_krw'].transform('std')
traj_mean = df.groupby('traj_id')['price_krw'].transform('mean')
traj_min = df.groupby('traj_id')['price_krw'].transform('min')
```

이유: 미래 데이터를 포함한 통계 → Data Leakage

실제 서비스에서는 DPD=60 시점에 DPD=1 가격을 알 수 없다.

허용되는 누적 통계 (현재까지만):

```
# DPD 높은 쪽(과거)부터 현재까지의 누적
cum_min = expanding().min() # 허용
cum_max = expanding().max() # 허용
cum_mean = expanding().mean() # 허용
cum_std = expanding().std() # 허용
cum_count = expanding().count() # 허용
```

레이블 생성 코드 (그대로 쓸 것)

```
import pandas as pd

# df는 (traj_id, dpd) 기준으로 정렬된 상태
# dpd 내림차순 = 시간순 (DPD=120이 가장 먼저 관측)
df = df.sort_values(['traj_id', 'dpd'], ascending=[True, False])

# saving_pct: 현재 가격이 이후 실제 최저가 대비 얼마나 비싼지
df['residual_min'] = (
    df.sort_values(['traj_id', 'dpd'])
      .groupby('traj_id')['price_krw']
      .transform(lambda x: x.expanding().min())
)
df['saving_pct'] = (
    (df['price_krw'] - df['residual_min']) / df['price_krw'] * 100
).clip(lower=0)

# cv_pct: 편명 단위 DPD 구간 변동계수 (DB 쿼리에서 직접 가져옴)
# ROUND(STD(price_krw)/AVG(price_krw)*100, 2) AS cv_pct
```

```
# 레이블
df['label'] = (df['saving_pct'] > df['cv_pct']).astype(int)
# 0 = BUY, 1 = WAIT
```

요약

항목	내용
레이블 정의	<code>saving_pct > cv_pct</code>
BUY(0) 의미	지금 사는 게 유리 (기다려도 변동성 범위 안에서만 내려감)
WAIT(1) 의미	기다리면 변동성 범위 이상으로 내려갈 가능성이 있음
타겟 변수	saving_pct (1단계 모델이 예측)
기준선	cv_pct (편명별 가격 변동계수)
금지 피처	saving_margin, traj_std/mean/min/max (leakage)
클러스터링	레이블 대체 불가, 피처로만 사용 가능